

空气质量四分类任务：经典与量子机器学习模型设计与性能分析

2025 年 5 月 13 日

摘要: 空气污染已成为全球性环境挑战，准确评估与预测空气质量对于城市可持续发展具有重要意义。本文围绕某空气质量预测竞赛任务，构建并比较了经典神经网络模型与量子机器学习模型的性能表现。我们首先实现了结构紧凑的多层感知机（MLP）与小型残差网络（ResNet），作为经典基线模型。在此基础上，提出了一种量子经典混合的多层感知机（QMLP）模型，采用参数化变分量子电路对输入特征进行建模。实验结果表明，在参数量更少的情况下，量子混合模型具备良好的预测潜力，并展现出较高的模型压缩效率与泛化能力。研究结果为量子机器学习在环境数据分析中的应用提供了实践探索与技术参考。

关键词: 机器学习；量子机器学习；量子经典混合；

1 概述

空气污染是全球性环境问题，对人类健康和生态系统产生了深远的影响。准确评估空气质量并预测污染等级对于制定环境保护政策和改善居民生活质量至关重要。本次比赛旨在利用量子机器学习技术，基于多维度的环境数据，预测空气质量等级，为城市环境管理提供决策支持。

我们在本地运行时的代码结构如下（代码仓库链接<https://github.com/YuZhuZhi/Problem2>）:

- **Data 文件夹:** 存放数据集 `train_data.csv` 和 `test_data.csv`。
- **Utils.py:** 实现数据读取、预处理等的工具类和函数。
- **ClassicalModel.py:** 实现经典机器学习模型的网络框架。
- **QuantumModel.py:** 实现量子机器学习模型的网络框架。
- **Trainer.py:** 实现模型训练和评估。
- **Main.py:** 主程序，负责调用各个模块，进行数据加载、模型训练和评估。

2 数据探索与预处理

本任务中提供了 `train_data.csv` 与 `test_data.csv` 两个数据集。两个文件具有相同的结构，从左到右依次为：温度（ $^{\circ}\text{C}$ ）、湿度（%）、 $\text{PM}_{2.5}$ 浓度（ $\mu\text{g}/\text{m}^3$ ）、 PM_{10} 浓度（ $\mu\text{g}/\text{m}^3$ ）、 NO_2 浓度（ppb）、 SO_2 浓度（ppb）、CO 浓度（ppm）、到最近工业区的距离（km）、人口密度（人/ km^2 ）、空气质量。其中，前九列是特征，最后一列即空气质量是标签，共有四类：Good、Moderate、Poor 和 Hazardous，在之后我们会将其映射为 0 ~ 3。

为了读取文件，我们在 `Utils.py` 文件中实现了 `CSVReader` 类。该类的构造函数读入一个数据集文件路径，自动加载文件中所有数据，包括列名、数据维度、缺失值等。通过调用函数，也可以查看读入数据的统计信息，例如均值和方差等。这个类中有以下方法：

- `__init__(self, filePath: str)`: 构造函数，传入数据集文件路径，自动读取数据集。
- `__loadData__(self)`: 读取数据集文件，没有返回值。会被构造函数自动调用，用户不得手动调用。
- `getData(self)`: 以二元组返回数据集的特征和标签。
- `checkBasicInfo(self)`: 输出检查数据集的基本信息，包括维度、缺失值等。

- `showStatistics(self)`: 输出数据集的统计信息, 包括均值、方差等。
- `read(filePath: str)`: 静态方法, 传入数据集文件路径, 返回数据集特征和标签。用于快速读取数据集。

一般而言, 为了模型能够更好地学习特征, 我们会对数据进行预处理。由于数据量较小, 简单的预处理即可完成需求。我们在 `Utils.py` 文件中实现了 `Math` 静态类。这个类中只有一个静态函数:

- `normalize(data: np.ndarray)`: 对数据进行归一化处理, 返回归一化后的数据。

这是为了保证不会修改 `CSVReader` 类中的数据。在 `Trainer.py` 文件中, `Trainer` 类读入数据后会自动调用 `Math.normalize` 函数对数据进行归一化处理。

3 经典神经网络模型

3.1 算法原理

我们实现了两种经典神经网络结构作为基准模型: 残差网络和多层感知器。

3.1.1 MLP (多层感知机)

给定样本集 (x, y) , 我们希望能从中学到函数变化 $f(\bullet)$, 对任给特征向量 x 能预测其真实的对应标签 y 。针对该任务, 最初的方法是使用线性分类器, 但该方法表示能力较差, 尤其对于线性不可分的数据无法很好将数据进行分类。

为了得到更好的分类结果, 我们希望我们的分类器能有更强的表达能力, 能表达出非线性函数变化。而仅叠加线性函数并不能得到非线性分类器, 如下所示两个矩阵相乘结果仍是表示线性变化的矩阵:

$$y = W_2(W_1x) = Wx$$

为了解决该问题, 多层感知机提出了一种新的设计思路, 在每次线性变化结束后跟一个非线性激活函数 $g(\bullet)$, 此时线性分类器变为了非线性分类器。同时, 已有研究已证明了当神经网络充分训练后, 神经网络可以拟合任意函数变化, 并且由于神经网络的复杂性, 在神经网络训练中, 往往存在过拟合现象。

- 前向传播:

顾名思义, 该方法从输入端开始逐步向前传播以得到输入数据最终的预测结果 \hat{y} , 即:

$$\hat{y} = (W_n \dots (W_2 g(W_1 x)))$$

其中, $g(\bullet)$ 为非线性激活函数。

同时, 在前向传播中我们也会将每个神经元节点的中间值进行存储, 该动作主要为了反向传播中计算损失函数对各参数的梯度, 更新参数以拟合标签。

- 反向传播:

由于神经网络往往是多层网络结构, 很难直接求出各参数的最优解, 在实际操作中, 我们通常使用随机梯度下降 (SGD) 求出模型的解析解, 即:

$$w_t = w_{t-1} + step \times (-gradient)$$

针对每个神经网络结构, 手动求出各节点关于损失函数的梯度显然是不可能的, 在数学上关于复合函数存在一种简单的计算方法——链式法则, 我们希望求出 $\frac{\partial \mathcal{L}}{\partial x}$, 根据链式法则仅需 $\frac{\partial \mathcal{L}}{\partial z}$ 和 $\frac{\partial z}{\partial x}$, 即:

$$\frac{\partial \mathcal{L}}{\partial x} = \frac{\partial \mathcal{L}}{\partial z} \frac{\partial z}{\partial x}$$

而 $\frac{\partial \mathcal{L}}{\partial z}$ 可以不断从输出端传回, $\frac{\partial z}{\partial x}$ 一般均是一个简单的函数模块, 可以直接求得梯度。通过不断反向传播逐步求得各节点的梯度, 进而根据梯度更新各节点的参数。

3.1.2 ResNet（残差网络）

网络的深度越深，意味着提取的特征越多，直观上讲，更深的网络应该带来更高的分类精度，但是实际上并不是这样。随着网络的加深第一次出现深度危机是由梯度消失和梯度爆炸所引起的，他们从训练开始就阻止收敛，这个问题已经可以通过归一初始化和中间归一化在很大程度上进行解决，使得网络可以从原来的几层堆叠至十几层。随着网络深度的加深，又出现了新的问题，随着网络深度增加，在训练集上的精度达到饱和，然后迅速下降。显然，这种现象不是过拟合造成的，因为过拟合会使得训练集上的精度极高。如果此时向一个深度适当的模型添加更多层的话会带来更高的训练误差，如下图所示，当层数增多反而误差增大。




图 3.1 层数增加无法正常训练

《Deep residual learning for image recognition》^[1]这篇论文就是为了解决上述“退化”问题提出的一种叫做残差网络的模型（如下图所示），该模型与之前神经网络模型不同，之前神经网络模型在输出层直接拟合期望 $H(x)$ ，而残差神经网络并没有直接拟合期望，而是拟合 $H(X) - x$ 这个函数，在提出这个模型的时候作者猜想，之所以加深层数之后无法对期望进行一个较好的拟合是因为求解器可能在拟合多层非线性恒等映射的问题上有困难，即假如前边层数的神经网络的已经有一个较好的输出期望，但是此时通过多层神经网络，需要将前边较好的输入与输出形成一个恒等的映射，但实验结果表明多层神经网络在形成该恒等映射上存在较大困难，因此在论文中作者提出了一种新的想法，利用残差学习重构，如果恒等映射是最优的，求解器可以简单地将多个非线性层的权值向零逼近以达到恒等映射，若非最优的，则假如多个线性层可以逐渐逼近复杂的函数，那么它也可以逐渐逼近残差函数，例如 $H(X) - X$ （假设输入和输出是相同维度的）。所以，我们让这些层来拟合 $F(X) = H(X) - X$ 而不是单独的 $H(X)$ 。那么原始函数就变成了 $F(X) + X$ 。即使两种函数都可以拟合，但是，学习的难易程度是不一样的。因此该种拟合残差的方法不仅可以保证其至少不会比层数更少的神经网络差，同时每块神经网络拟合的是 $F(X) = H(X) - X$ 而不是 $H(X)$ ，在函数映射的复杂度上应该会更低，因此在理论层面上，该种神经网络对于解决上述“退化”问题极有可能表现出很强的优越性，论文作者在多个实验种也证明了该模型在实践层面上确实有着非常强的优越性。




图 3.2 残差块结构

上述残差模型解决了堆叠深度时存在的核心问题——增加深度反而导致精度下降，使得神经网络可以




图 3.3 smallMLP 网络结构

从十几层堆叠至几十层甚至几百层。同时该模型还有许多其他优点：

- 整个网络依然能够端到端地使用反向传播算法训练
- 残差神经网络很容易地使用公共库实现，且无需修改求解器
- 深度残差网络很容易从大幅增加的深度上获得精度提升，结果要大幅优于之前的网络。

3.2 实现细节

我们实现的一个 MLP 网络结构如图3.3所示，由于其规模较小，称为 **smallMLP**。该网络包含一个输入层、两个隐藏层和一个输出层。输入层有 9 个节点，分别对应 9 个特征；第一个隐藏层有 8 个节点，第二个隐藏层有 6 个节点；输出层有 4 个节点，分别对应四类标签。每一层的神经元之间是全连接的。在这个网络中，共计使用 **162** 个参数。

另一方面，我们还实现了一个小型的残差网络（**smallResNet**）如图3.4所示，以期能取得更好的效果。该网络大体结构与 **smallMLP** 相同，但对于残差连接结构，使用了 $8 \rightarrow 4 \rightarrow 8$ 的结构。**Linear1** 层的输出结果，会直接与 **Res1A** 层的输出结果相加，作为 **Res1B** 层的输入，即图3.4中的红色虚线所示。在这个网络中，共计使用 **192** 个参数。

3.3 性能评估

使用多层感知机与残差网络对数据集进行训练，得到如表3.1所示的实验结果。

表 3.1 经典模型的训练结果

迭代次数	经典模型	训练准确率	测试准确率	测试 F1 分数
50	SmallMLP	69.55%	66.10%	0.3993
	SmallResNet	74.37%	75.30%	0.5564
250	SmallMLP	86.98%	85.60%	0.6645
	SmallResNet	87.02%	85.50%	0.6632
500	SmallMLP	87.15%	85.50%	0.6635
	SmallResNet	87.37%	85.80%	0.6662




图 3.4 SmallResNet 网络结构（含残差连接）

根据实验结果可知，在固定参数大小下，经典的神经网络模型 ResNet 与 MLP 的实验精度基本一样，使用更复杂的 ResNet 模型对实验的结果精度并未产生较大提升。从模型理论上讲，由于更复杂的模型 (ResNet) 在提出的时候往往是解决增加模型参数却不能极大提高准确率的问题，而在该任务中所用经典参数较少，并未达到 MLP 的模型性能极限，因此使用 ResNet 并未提升较大精度。

由以上实验分析，我们可以提出如下假设：在固定参数下，存在经典模型并未超出其性能极限，即在固定参数下更改模型并不能提升预测精度。在此假设下，我们希望存在某种模型能够在原有经典模型的基础上，能进一步较大提升模型的预测精度，从而减少模型的参数量，进而提高模型的计算效率。

4 量子机器学习模型

4.1 算法原理

Algorithm 1 QMLP 训练流程

- 1: 初始化参数 $\{\theta_l\}_{l=1}^L$ 和 $\{f_l\}_{l=1}^L$
 - 2: **for** 每个训练 epoch **do**
 - 3: 编码输入: $|\phi_0\rangle = S(\mathbf{x})|0\rangle^{\otimes N}$
 - 4: 量子态演化: $|\phi_L\rangle = \prod_{l=1}^L U_l(\theta_l)|\phi_0\rangle$
 - 5: 参数化纠缠: $|\phi_L\rangle = \bigotimes_{m=1}^{N/2} CRX(\phi_m)|\phi_L\rangle$
 - 6: 重传: $|\phi_L\rangle = R_l(\mathbf{x})|\phi_L\rangle$
 - 7: 测量期望值: $\langle Z \rangle_i = \langle \phi_L | Z_i | \phi_L \rangle$
 - 8: 计算损失: $\mathcal{L} = -\sum_c y_c \log p_c$
 - 9: 通过参数偏移规则更新参数
 - 10: **end for**
-

在本次报告中，我们实现的量子机器学习模型为 QMLP (Quantum Multi-Layer Perceptron)^[2]，流程如算法1和图4.1所示。

QMLP 是基于变分量子算法的量子神经网络模型，主要由以下几个部分组成：

4.1.1 量子数据编码

QMLP 采用线性旋转编码将经典数据映射到量子态：




图 4.1 QMLP 算法流程图

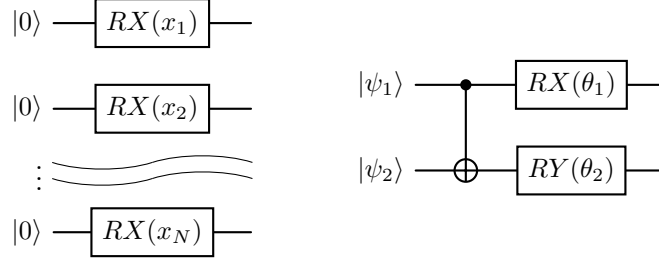


图 4.2 左：量子数据编码电路；右：参数化纠缠层电路

$$S(\mathbf{x}) = \bigotimes_{k=1}^N RX(x_k) \quad (4.1)$$

这个电路都构造非常简单，如图4.2左图所示。由此我们将经典数据映射到量子态，同时通过单比特旋转门独立编码每个输入特征，达到抑制噪声传播的目的。

4.1.2 变分量子电路

在对输入进行量子编码后，便可以对其应用式4.2对应的变分量子电路进行参数化么正变换（类似于经典神经网络中的权重矩阵乘法）。

$$|\phi_L\rangle = \prod_{l=1}^L U_l(\theta_l) |\phi_0\rangle \quad (4.2)$$

$U_l(\theta_l)$ 表示由一组可训练参数 θ_l 控制的么正变换， $|\phi_0\rangle$ 表示编码后的输入态。

然后相邻量子比特之间应用 CRX 门 (式4.3) 创建纠缠，增强局部关联性。电路如图4.2右图所示。

$$|\phi_L\rangle = \bigotimes_{m=1}^{N/2} CRX(\phi_m) |\phi_L\rangle \quad (4.3)$$

CRX 门的矩阵表达为式4.4。

$$CRX(\theta) = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & \cos \theta/2 & -i \sin \theta/2 \\ 0 & 0 & -i \sin \theta/2 & \cos \theta/2 \end{pmatrix} \quad (4.4)$$

4.1.3 重上传单元

接着对每一位输入进行重传 (式4.5)，重复注入编码层 $S(\mathbf{x})$ 在变分电路中生成输入的高阶项引入非线性（类似于经典电路的激活函数），增强量子神经网络的表达能力。

$$|\phi_L\rangle = R_l(\mathbf{x}) |\phi_L\rangle \quad (4.5)$$

R_l 表示所用的重传单元如 RX, RY 门

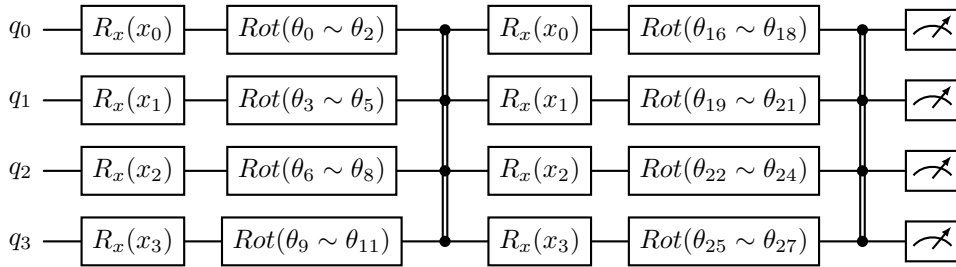

4.1.4 测量与优化

通过 Pauli-Z 基测量 (式4.6) 将处理后的量子态转换为经典可读信号，然后便可应用经典方法如 Adam 优化算法等对模型参数进行优化。

$$\langle Z_i \rangle = \langle \phi_L | Z_i | \phi_L \rangle \in [-1, 1] \quad (4.6)$$

4.2 实现细节

出于效率的考量，我们采用了量子经典混合的架构，即首先由经典神经网络将 9 维的输入降维到 4 维，之后将这些数据输入到 QMLP 中，最后的测量结果就是输出。整个架构如图4.3之子图 1 所示，而其中的“Quantum Circuit”部分具体如图4.3之子图 2 所示。在子图 2 中， $Rot(\theta_i \sim \theta_{i+2})$ 表示了一套需要三个量子参数的 RX, RY, RZ 门组合；而四个相连受控位表示一套 CRX 门组合，需要四个量子参数，分别如图4.3之子图 3,4 所示。显而易见，在这个架构中，经典参数量为 $9 \times 4 + 4 = 40$ ，而量子参数量为 $8 \times 3 + 2 \times 4 = 32$ 个，总共 **72** 个参数。



$$\text{---} \boxed{Rot((\theta_i \sim \theta_{i+2}))} \text{---} = \text{---} \boxed{RX(\theta_i)} \boxed{RY(\theta_{i+1})} \boxed{RZ(\theta_{i+2})} \text{---}$$




图 4.3 自上而下：子图 1: QuantumMLP 网络结构图：线性映射 + 参数化量子电路 + 测量输出；

子图 2: 参数化量子电路的具体实现；

子图 3: $Rot(\theta_i \sim \theta_{i+2})$ 门的具体实现；

子图 4: CRX 门组合的具体实现。

4.3 性能评估

使用如图4.3的结构对数据集进行训练，得到如表4.1所示的实验结果。

表 4.1 量子经典混合模型的训练结果

迭代次数	训练准确率	测试准确率	测试 F1 分数
50	75.98%	76.60%	0.6004
150	89.19%	87.20%	0.8000
250	92.95%	90.80%	0.8880
500	93.33%	90.90%	0.8820

对比表3.1，我们可以可见量子混合模型的独特学习特性：

- 早期收敛优势：150 次迭代即达 87.20% 测试准确率，超过经典模型最终收敛值 (85.80%)
- 稳定收敛阶段：250-500 次迭代期间测试准确率仅提升 0.3 个百分点，表明模型在中期即进入平台期

5 性能对比与分析

5.1 性能对比

表 5.1 经典机器学习与量子机器学习的性能对比

模型	参数量	训练准确率	测试准确率	测试 F1 分数
经典小型 ResNet	192	87.37%	85.80%	0.6662
量子经典混合 MLP	72	93.33%	91.00%	0.8820

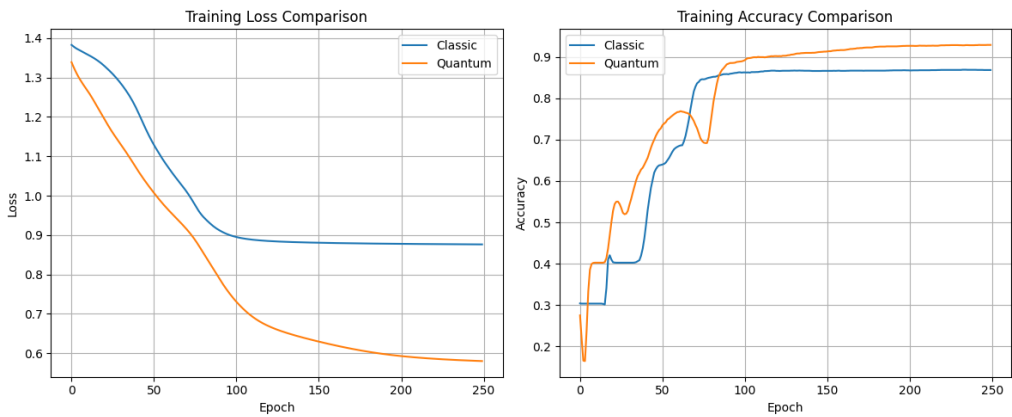


图 5.1 经典与量子模型的训练收敛曲线及准确率对比

通过表 5.1与图 5.1的对比实验，量子经典混合 MLP 展现出以下核心优势：

- 参数效率优势：
 - 参数量仅为 72，相比经典小型 ResNet（192 参数）减少 62.5%
 - 实现参数压缩的同时保持高性能，体现量子计算的紧凑表示能力
 - 更小的内存占用（理论存储需求降低至经典模型的 37.5%）
- 收敛优势：
 - 量子态叠加特性增强了对特征空间的探索能力，训练曲线显示量子模型在 250 epoch 内能够不断降低，最终收敛到一个较低值。

- 相比经典模型，收敛到相同的损失值速度更快，经典模型容易停留在局部最优解，而量子模型能够跳出局部最优解，从而达到更高的精度
- 准确率优势：
 - 测试准确率 91.00% 显著高于经典模型的 85.80%
 - 测试 F1 分数 0.8820，相比经典模型提升 32.4%，这说明量子模型在精确率和召回率之间取得了更好的平衡，更适合处理类别不平衡数据

5.2 差异分析

表 5.2 量子与经典神经网络核心组件对比

功能	经典神经网络组件	QMLP 组件
输入编码	数据标准化层 $\mathbf{x} \in \mathbb{R}^n \rightarrow \text{Norm}(\mathbf{x})$	单比特旋转门编码 $S(\mathbf{x}) = \bigotimes_k RX(x_k)$
特征变换	全连接层 $W\mathbf{x} + \mathbf{b}$	变分量子电路 $U(\theta) \phi\rangle$
非线性引入	激活函数 $\text{ReLU}(x) = \max(0, x)$	数据重上传单元 (RUU) $R_l(\mathbf{x}) = RX(f_l(\mathbf{x}))$
参数优化	梯度下降 $\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$	参数偏移规则 $\nabla_{\theta} \langle Z \rangle \approx \frac{\langle Z \rangle_{\theta+\delta} - \langle Z \rangle_{\theta-\delta}}{2}$
输出处理	Softmax 分类层 $p_c = \frac{e^{y_c}}{\sum e^{y_i}}$	Pauli-Z 测量 $\langle Z \rangle_i = \langle \psi Z_i \psi \rangle$

通过表 5.2 的组件对比分析，我们推断 QMLP 的架构创新主要体现为以下五个维度的量子特性优势，很可能是这些优势共同支撑了其性能的显著提升：

- 量子态编码：单比特旋转门 $RX(x_k)$ 将经典数据映射到 Bloch 球面，实现 $\mathbb{R}^n \rightarrow \mathbb{C}^{2^n}$ 的维度扩展，比经典标准化层保留更多信息
- 量子并行计算：变分量子电路 $U(\theta)|\phi\rangle$ 通过量子纠缠产生叠加态，实现对经典全连接层的加速计算
- 动态非线性：数据重上传单元 (RUU) 通过 $RX(f_l(\mathbf{x}))$ 形成自适应非线性响应，比 ReLU 激活函数具有更强的边界拟合能力
- 高效优化：参数偏移规则 $\nabla_{\theta} \langle Z \rangle$ 直接利用量子态特性计算梯度，比经典反向传播具有更高精度
- 量子测量：Pauli-Z 测量 $\langle Z \rangle_i$ 通过量子干涉效应提取全局特征，比 Softmax 具有更强的表征能力

上述量子特性通过协同作用形成正向循环：量子编码的几何优势增强特征表达 → 量子并行性加速特征抽取 → 动态 RUU 提升模型容量 → 参数偏移规则优化训练效率 → 量子测量实现信息蒸馏。这种量子-经典的协同机制，最终使得 QMLP 模型在相同任务上相比传统模型取得了参数和正确率的双重优势。

参考文献

- [1] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[A/OL]. 2015. arXiv: 1512.03385. <https://arxiv.org/abs/1512.03385>.
- [2] CHU C, CHIA N H, JIANG L, et al. Qmlp: An error-tolerant nonlinear quantum mlp architecture using parameterized two-qubit gates[A/OL]. 2022. arXiv: 2206.01345. <https://arxiv.org/abs/2206.01345>.